CHAPTER

07

생성형 인공지능의 윤리적 이슈

① 생성형 인공지능에서 발생하는 할루시네이션

이유

생성형 인공지능(Generative Artificial Intelligence, 생성형 AI)은 그 놀라운 성능을 바탕으로 우리 생활에 빠르게 도입되고, 다양한 분야에서 활용되고 있다. 그러나 아무리 훌륭하다 해도 완벽하지는 않으며, 생성형 AI 역시 몇 가지 윤리적 문제와 한계를 가지고 있다. 결국 인공지능(AI)은 도구이고 그 도구를 어떻게 활용할 것인지, 도구로 인한 문제점은 없는지 판단하고 결정해야 하는 것은 우리들이다. 생성형 AI가 어떤 문제를 가지고 있으며 그 원인이 무엇인지 파악하고 현명하게 활용해 보자.

- **데이터의 불완전성**: AI 모델은 대규모 데이터셋을 학습하지만, 데이터셋이 완벽하지 않기 때문에 부정확하거나 잘못된 정보를 학습할 수 있다.
- **모델의 복잡성**: 복잡한 모델 구조는 고차원 데이터의 패턴을 잘 잡아낼 수 있지만, 때로는 존재하지 않는 패턴을 만들어 내어 잘못된 정보를 생성한다.
- **확률적 생성**: 생성형 AI 모델은 확률적인 방법으로 데이터를 생성하기 때문에, 비현실적이거나 부정확한 결과를 만들어 낼 수 있다.
- **콘텍스트 이해 부족**: AI 모델은 인간처럼 상황과 문맥을 완전히 이해하지 못해 문맥에 맞지 않는 정보를 생성할 수 있다.

윤리적 문제

위에서 제시한 것처럼 생성형 AI가 생성한 결과는 부정확하거나 신뢰도가 낮은 정보일 수도, 심지어 비현실적일 수도 있다. 이런 과정에서 발생하는 대표적인 문제 중 하나가 할루시네이션(Hallucination)이다. 생성형 AI의 할루시네이션은 AI 모델이 비논리적이거나 부정확한 출력을 생성하는 현상을 말한다. 이는 불완전하거나 편향

된 훈련 데이터, 과적합, 모델의 일반화 능력 부족 등 여러 이유로 발생할 수 있다. 이러한 할루시네이션은 의료, 금융, 의사결정 등 중요한 분야에서 상당한 윤리적 및 실용적 문제를 초래한다(MIT Sloan TechLearn, Telus International) .

- **잘못된 정보 확산**: AI가 생성한 잘못된 정보가 인터넷을 통해 확산되면, 오해와 혼란을 초래할 수 있다.
- **신뢰성 저하**: AI 시스템이 반복적으로 할루시네이션을 일으키면, 사용자들이 AI 기술에 대한 신뢰를 잃게 된다.
- **책임 문제**: AI가 생성한 잘못된 정보로 인한 피해가 발생했을 때, 그 책임을 누구에게 물어야 하는지가 명확하지 않다.
- **윤리적 결정**: 할루시네이션으로 인해 부적절하거나 비윤리적인 콘텐츠가 생성될 경우, 그로 인한 사회적 문제를 어떻게 해결할 것인지에 대한 논의가 필요하다.

할루시네이션을 방지하기 위한 새로운 기술 및 연구

할루시네이션 문제를 해결하기 위해 다양한 기술과 연구가 활발히 진행되고 있다. 첫 번째로, 데이터의 품질을 개선하는 접근법이 주목받고 있다. 더 정확하고 신뢰할 수 있는 데이터를 수집하고, 데이터 정제 과정을 통해 편향된 정보나 오류를 최소화함으로써 모델의 학습 과정을 강화하려는 것이다. 두 번째로, AI 모델의 답변을 검증하는 기술이 개발되고 있다. 생성된 정보의 정확성을 확인하기 위해 외부 데이터베이스나 신뢰할 수 있는 정보를 참조하여 결과를 비교하는 방식이다. 마지막으로 설명 가능한 인공지능(Explainable AI, XAI)와 같은 기술을 통해 모델이 왜 특정 결과를 생성했는지 이해할 수 있도록 만들어, 잘못된 정보 생성의 원인을 분석하고 수정할 수 있도록 지원한다.

- **데이터 검증 및 정제**: 학습 데이터셋을 정교하게 검증하고 정제하여 잘못된 정보가 포함되지 않도록 한다. 고품질의 데이터셋을 사용하여 모델의 신뢰성을 높인다.
- **모델의 투명성 및 해석 가능성**: 모델의 의사결정 과정을 투명하게 공개하고 해석

가능하게 만들어 사용자들이 결과를 이해하고 신뢰할 수 있도록 한다.

- **컨텍스트 인식 강화**: AI 모델이 문맥을 더 잘 이해할 수 있도록 자연어 처리 기술을 개선한다. 예를 들어, 최신의 Transformer 기반 모델들은 더 깊은 문맥 이해를 가능하게 한다.
- **피드백 루프**: 사용자의 피드백을 지속해서 수집하고, 이를 통해 모델을 업데이트하여 성능을 개선한다. 이는 AI가 실시간으로 학습하고 발전하는 데 도움이 된다.
- **혼합 데이터 소스 사용**: 다양한 소스에서 데이터를 수집하여 모델이 편향되지 않도록 한다. 이를 통해 모델의 다양성과 정확성을 높인다.
- **안전장치 및 제어 메커니즘**: AI가 비정상적인 출력을 생성할 때 이를 감지하고 차단할 수 있는 안전장치를 마련한다. 예를 들어, 정밀한 기준에 맞지 않는 출력을 자동으로 걸러내는 필터링 시스템을 구축한다.
- **신경망의 개선**: 최신 신경망 구조와 학습 기법을 도입하여 모델이 더 정교하게 학습하도록 한다. 예를 들어, Attention 메커니즘을 활용하여 특정 부분에 더 집중하도록 한다.
- **하이브리드 모델**: 규칙 기반 시스템과 머신러닝 모델을 결합하여, 할루시네이션 가능성을 줄이고 더 안정적인 출력을 보장한다.
- **학습 중간 점검**: 모델 학습 중간 단계에서 정기적으로 성능을 점검하고, 잘못된 경향이 발견되면 조기에 수정한다.
- **책임 있는 AI 개발 프레임워크**: AI 개발 과정에서 윤리적 가이드라인을 엄격히 준수하고, 개발자들이 책임감을 가지고 모델을 설계하도록 한다.

이러한 기술적 접근과 연구는 생성형 AI의 할루시네이션 문제를 해결하는 데 중요한 역할을 한다. 지속적인 연구와 기술 발전을 통해 AI의 신뢰성과 안전성을 높이는 것이 필수적이다.

주요 연구 및 해결책

- **할루시네이션 비율 추정**: 연구자들은 생성형 AI 모델의 할루시네이션 비율을 추정하기 위한 방법을 개발했다. 이 방법은 모델의 출력이 실제 데이터 분포와 얼마나 일치하는지 평가하여 할루시네이션 발생 확률을 추정한다(ar5iv).
- **모듈형 프롬프트 및 데이터 증강**: 모듈형 프롬프트 시스템을 사용하여 특정 쿼리 유형과 데이터 컨텍스트에 맞게 AI 모델을 최적화하는 혁신적인 해결책이 있다. 이 시스템은 쿼리 의도를 분류하고, 데이터 청크를 생성하며, 맞춤형 프롬프트를 만들어 할루시네이션을 최소화한다. 또한, 응답의 맥락적 및 문법적 정확성을 평가하는 모듈을 사용한다(ar5iv).
- **Retrieval-Augmented Generation(RAG)**: RAG 기법은 AI 모델에 인덱스화된 데이터베이스에서 관련 데이터를 검색하는 리트리버 컴포넌트를 추가하여 생성을 지원한다. 이를 통해 AI의 응답이 정확하고 관련성 있는 정보에 기반하여 할루시네이션 가능성을 줄인다(ar5iv).
- **인간 피드백 및 지속적인 품질 관리**: 인간 피드백을 학습 과정에 포함시키는 강화학습(RLHF)은 AI 모델이 더 정확한 출력을 생성하도록 도와줍니다. 또한, 적대적 예제 및 이상 탐지 기능을 포함한 지속적인 품질 관리 방법을 통해 AI의 성능을 모니터링하고 개선한다(Telus International).

실제 사례 및 연구

- **금융 분야**: 금융 부문에서는 할루시네이션이 치명적인 결과를 초래할 수 있다. 이를 해결하기 위해 모듈형 프롬프트와 맞춤형 데이터 처리를 통해 할루시네이션을 최소화하는 Langchain 기반 시스템과 같은 프레임워크가 개발되었다(ar5iv).
- **의료 분야**: 의료 분야에서는 AI 시스템이 다양한 포괄적인 데이터셋으로 훈련되어야 할루시네이션을 방지할 수 있다. 전문가 지식과의 지속적인 검증과 업데이트가 필수적이다(Telus International).

추가 자료 및 참고문헌

다음 논문과 기사를 통해 이러한 접근법과 구현에 대해 자세히 알아볼 수 있다:

- Estimating the Hallucination Rate of Generative AI
- Journey of Hallucination-minimized Generative AI Solutions
- Reducing hallucination in structured outputs via Retrieval-Augmented Generation
- Addressing AI Hallucinations and Bias

이 자료들은 생성 AI의 할루시네이션 문제를 완화하기 위한 고품질 데이터, 맞춤형 프롬프트 시스템, 지속적인 인간 감독의 중요성을 강조하며, 현재 연구와 실질적인 해결책에 대한 포괄적인 개요를 제공한다.

❷ 설명 가능한 인공지능(Explainable AI, XAI)

설명 가능한 인공지능(XAI)은 인공지능 시스템의 의사결정 과정을 인간이 이해할 수 있도록 설명하는 기술이다. XAI는 AI의 복잡한 내부 작동 방식을 투명하게 만들어, 사용자와 개발자가 AI의 결과를 신뢰하고 검증할 수 있도록 돕다. XAI의 주요 목표는 AI 모델의 결과를 설명 가능하게 하고, 예측의 이유를 명확히 하여 신뢰성과 투명성을 높이는 것이다.

Generative AI에서 XAI가 필요한 이유

- **투명성 및 신뢰성:** 생성형 AI는 텍스트, 이미지, 음악 등 다양한 콘텐츠를 생성할 수 있다. 그러나 생성 과정이 불투명하면 결과물의 품질과 신뢰성을 보장하기 어렵다. XAI는 생성형 AI의 내부 작동 방식을 설명하여 사용자가 결과물을 신뢰할 수 있도록 한다.
- **윤리적 문제 및 편향성:** 생성형 AI는 학습 데이터의 편향성을 그대로 반영할 수 있으며, 이는 부정확하거나 편향된 결과로 이어질 수 있다. XAI는 AI 모델이 어

떤 데이터를 기반으로 학습했는지, 어떤 논리로 결정을 내렸는지 설명하여 편향 문제를 식별하고 수정하는 데 도움을 준다.

- **법적 및 규제 요구사항**: 일부 산업에서는 AI의 결정 과정에 대한 설명이 법적으로 요구된다. 예를 들어, 금융 산업에서는 대출 승인 여부를 결정하는 AI 모델의 논리를 설명할 수 있어야 한다. XAI는 이러한 규제 요구를 충족하는 데 필수적이다.
- **사용자 피드백 및 개선**: XAI는 사용자에게 AI의 결정 과정을 설명함으로써 더 나은 피드백을 받을 수 있게 한다. 이를 통해 AI 시스템을 지속적으로 개선할 수 있다.

XAI의 구현과 원리

설명 가능한 인공지능(XAI)을 구현하기 위한 몇 가지 방법을 소개하고, 그 원리를 일반인들이 이해하기 쉽게 설명하고자 한다.

- 모델 해석 방법

a. **특성 중요도**(Feature Importance)

– **원리**: AI 모델이 예측을 할 때 어떤 입력 특성이 중요한 역할을 했는지 파악하는 방법이다.

– **설명**: 예를 들어, AI가 주택 가격을 예측한다고 가정해 보자. 이 모델은 주택의 크기, 위치, 방의 수 등을 고려할 수 있다. 특성 중요도 분석을 통해 모델이 주택 가격 예측에서 가장 중요하게 여기는 특성이 무엇인지 알 수 있다. 이렇게 하면 "모델이 방의 수가 많을수록 가격이 높아질 가능성이 크다고 판단했다"라는 식으로 설명할 수 있다.

b. **국지적 해석 가능 모델**(Local Interpretable Model-agnostic Explanations; LIME)

– **원리**: 모델의 특정 예측을 설명하기 위해 해당 예측 주변의 입력 데이터를 변형하여 모델의 반응을 관찰하는 방법이다.

– **설명**: 어떤 환자의 병을 진단하는 AI 모델이 있다고 가정해 보자. 이 모델이 왜

특정 환자가 당뇨병에 걸릴 가능성이 높다고 예측했는지 알고 싶다면, LIME을 사용해 이 환자의 여러 특성을 조금씩 변경해 본다. 예를 들어, 나이를 5살 낮추거나 혈당 수치를 약간 올려보는 식이다. 이때 모델의 예측이 어떻게 변하는지 관찰하면, "모델은 주로 혈당 수치와 나이에 기반해 당뇨병 가능성을 높게 평가했다"라고 설명할 수 있다.

- 모델의 시각화 방법

a. **결정 트리**(Decision Trees)

- **원리**: 결정 트리는 예측을 위해 분기 구조를 사용하여 쉽게 이해할 수 있는 시각적 설명을 제공한다.
- **설명**: 결정 트리를 생각해 보자. 이 트리는 여러 가지 질문으로 구성된 경로를 따라가면서 결정을 내린다. 예를 들어, AI가 이메일이 스팸인지 아닌지 분류한다고 가정해 보자. 결정 트리는 "이메일에 '무료'라는 단어가 포함되어 있습니까?"와 같은 질문을 하고, 이에 따라 "예" 또는 "아니오"로 나뉘어 최종 결정에 도달한다. 이렇게 하면 모델이 어떻게 예측했는지 쉽게 시각적으로 이해할 수 있다.

b. **샤플리 값**(Shapley Values)

- **원리**: 게임 이론에서 차용한 방법으로, 각각의 특성이 예측에 얼마나 기여했는지 계산하여 설명한다.
- **설명**: 샤플리 값을 사용하면, AI 모델이 특정 예측을 할 때 각 입력 특성이 얼마나 중요한 역할을 했는지 알 수 있다. 예를 들어, AI가 고객의 대출 승인 여부를 결정할 때, 샤플리 값은 소득, 신용 점수, 대출 금액 등의 특성이 각각 얼마나 영향을 미쳤는지 알려준다. "이 고객의 대출이 승인된 주된 이유는 높은 신용 점수와 안정된 소득 덕분이다"라고 설명할 수 있다.

- 모델의 단순화 방법

a. **모델 디스틸레이션**(Model Distillation)

- **원리**: 복잡한 모델을 더 단순한 모델로 변환하여 이해하기 쉽게 만드는 방법이다.
- **설명**: 모델 디스틸레이션은 복잡한 AI 모델(예: 심층 신경망)의 예측 결과를 간단한 모델(예: 선형 회귀 또는 결정 트리)로 학습시키는 것이다. 이렇게 하면 간단한 모델을 통해 원래 복잡한 모델의 예측을 설명할 수 있다. 예를 들어, 심층 신경망이 매우 복잡한 방식으로 고객의 대출 신청을 평가하지만, 디스틸레이션

을 통해 간단한 결정 트리를 사용해 "높은 소득과 신용 점수가 대출 승인에 중요한 요소였다"라고 설명할 수 있다.

- 적용 사례

– **의료 분야**: AI가 질병을 진단할 때, 특성 중요도와 LIME을 사용하여 의사들이 AI의 결정을 이해하고 신뢰할 수 있도록 한다.

– **금융 분야**: 대출 승인 모델에서 샤플리 값과 모델 디스틸레이션을 사용해 대출 심사관이 AI의 결정을 설명하고 고객에게 전달할 수 있도록 한다.

– **자율주행차**: 자율주행차의 의사결정을 설명하기 위해 결정 트리와 LIME을 사용하여 특정 상황에서 차량이 왜 특정한 행동을 했는지 설명한다.

추가 자료 및 참고문헌

- LIME: Local Interpretable Model-agnostic Explanations
- Shapley Values
- Decision Trees

이와 같은 방법들을 통해 AI의 결정 과정을 더 명확하게 이해하고 설명할 수 있다. 이는 AI의 투명성과 신뢰성을 높이는 데 중요한 역할을 한다.

XAI의 적용 사례

- 의료 분야

– **의료 영상 분석**: XAI는 의료 영상 분석 AI 모델이 특정 병변을 진단할 때 어떤 특징을 기반으로 판단했는지 설명한다. 이를 통해 의료진은 AI의 진단 결과를 검증하고 신뢰할 수 있다.

– **약물 추천 시스템**: AI가 환자에게 맞는 약물을 추천할 때, XAI는 그 추천이 어떻게 이루어졌는지 설명하여 의사들이 결정을 이해하고 신뢰할 수 있도록 한다.

- 금융 분야

– **대출 심사**: 금융 기관에서 대출 신청을 검토할 때 AI가 심사 결과를 설명할 수 있어야 한다. XAI는 대출 승인 또는 거절의 이유를 명확히 하여 고객의 이해를

돕고, 불필요한 분쟁을 줄인다.

- **사기 탐지**: AI가 금융 거래에서 사기를 탐지할 때, 어떤 패턴이 의심스러운 거래로 식별되었는지 설명함으로써 더 정확한 사기 탐지가 가능하다.

- **자율주행차**: 자율주행차 AI 시스템이 내린 결정(예: 차선 변경, 속도 조절 등)에 대한 설명이 필요하다. XAI는 이러한 결정의 이유를 설명하여 사고 발생 시 책임 소재를 명확히 하고, 신뢰성을 높인다.
- **법률 분야**: 법률 문서 작성이나 판례 분석에 AI를 활용할 때, AI의 결정 근거를 설명함으로써 법조인들이 그 결과를 이해하고 신뢰할 수 있다. 이는 AI의 활용 범위를 확대하는 데 중요한 역할을 한다.

추가 자료 및 참고문헌

- MIT Technology Review: Explainable AI and its importance
- World Economic Forum: The significance of XAI
- My Modern Met: Applications of Explainable AI

XAI는 AI의 투명성과 신뢰성을 높이고, 다양한 산업 분야에서 AI의 활용을 확장하는 데 중요한 역할을 한다. 이는 AI의 결정 과정을 이해하고 검증할 수 있게 하여 더 나은 의사결정을 지원하고, 윤리적 문제를 해결하는 데 기여한다.

❸ 생성형 인공지능의 학습에서 발생하는 저작권 침해 문제

생성형 AI는 다양한 콘텐츠를 생성하는 과정에서 저작권 침해 문제를 일으킬 수 있다. 이러한 문제는 주로 AI가 기존의 저작물을 학습 데이터로 사용하면서 발생한다. 이로 인해 생성된 콘텐츠가 원저작물과 유사하거나 동일한 요소를 포함할 경우, 저작권 침해로 간주될 수 있다. 이는 AI 기술의 윤리적 문제로 대두되며, 여러 측면에서 논의되고 있다.

윤리적 문제

- **저작권 보호**: AI가 저작권이 있는 콘텐츠를 학습하고 이를 바탕으로 새로운 콘텐츠를 생성할 때, 원저작자의 권리를 침해할 수 있다. 이는 창작자의 창작 의욕을 저하시킬 뿐만 아니라 법적 문제를 초래할 수 있다.
- **크리에이터의 권리 침해**: AI가 생성한 콘텐츠가 원저작물과 매우 유사한 경우, 원저작자의 노고와 창작물을 무단으로 사용하는 셈이 되어 크리에이터의 권리를 침해할 수 있다.
- **법적 책임**: AI가 생성한 콘텐츠로 인해 저작권 침해가 발생했을 때, 그 책임이 AI 개발자, 사용자, 또는 AI 자체에 있는지 명확하지 않다는 법적 문제도 있다.

저작권 침해를 방지하기 위한 기술 및 연구

- **데이터 사용 규제**: AI 학습 데이터에 대한 엄격한 규제와 관리가 필요한다. 이는 저작권이 있는 콘텐츠를 무단으로 사용하지 않도록 하기 위한 법적, 윤리적 가이드라인을 포함한다.
- **저작권 필터링 기술**: AI가 생성한 콘텐츠를 실시간으로 모니터링하고, 저작권 침해 가능성이 있는 부분을 자동으로 필터링하는 기술이 개발되고 있다. 이러한 기술은 저작권 침해를 예방하는 데 중요한 역할을 한다.
- **트랜스퍼 러닝 및 데이터 보호**: 트랜스퍼 러닝 기술을 사용하여 AI가 저작권이 없는 데이터셋을 활용하도록 함으로써 저작권 침해 문제를 방지할 수 있다. 또한, 데이터셋 자체에 대한 보호 및 관리 기술도 중요하다.
- **라이선스 관리 시스템**: AI 학습 데이터 및 생성 콘텐츠에 대한 라이선스 관리 시스템을 구축하여, 사용자가 저작권을 침해하지 않도록 도움을 줄 수 있다. 이러한 시스템은 콘텐츠 생성 시 저작권 상태를 확인하고 관리하는 기능을 제공한다.

관련 연구 및 기술 사례

- **Google의 BigGAN과 관련된 연구**: Google의 BigGAN 모델은 생성된 이미지가 원저작물과 유사하지 않도록 생성 과정에서 저작권 보호를 고려한 기술을 사용한다. 이는 데이터셋 필터링 및 모니터링 기술을 통해 구현된다.
- **OpenAI의 GPT 모델과 저작권 이슈**: OpenAI는 GPT 모델을 개발하면서 저작권 문제를 해결하기 위한 다양한 접근법을 연구하고 있다. 예를 들어, GPT-3 모델은 훈련 데이터셋에 저작권이 없는 데이터만 사용하도록 설계되었다.
- **법적 프레임워크 연구**: MIT와 하버드 대학 등 여러 학술 기관에서는 AI의 저작권 침해 문제를 해결하기 위한 법적 프레임워크를 연구하고 있다. 이러한 연구는 AI와 관련된 법적 책임을 명확히 하고, 저작권 보호를 강화하는 방안을 모색한다.

저작권 침해 문제를 해결하기 위해서는 기술적 접근뿐만 아니라 법적, 윤리적 측면에서도 다각적인 노력이 필요한다. 지속적인 연구와 발전을 통해 AI 기술의 윤리적 문제를 최소화하고, 창작자와 사용자가 모두 보호받을 수 있는 환경을 조성하는 것이 중요하다.

나이트 쉐이드: Generative AI에서 발생하는 저작권 문제 해결

나이트 쉐이드(Nightshade)는 시카고 대학의 연구팀이 개발한 도구로, 생성형 AI가 저작권을 침해하지 않도록 돕기 위해 설계되었다. 이 도구는 데이터 포이즈닝(data poisoning) 기술을 사용하여 AI 모델이 아티스트의 작품을 학습 데이터로 무단 사용하지 못하게 한다.

- **픽셀 변경**: 나이트 쉐이드는 이미지를 인간의 눈에는 보이지 않는 방식으로 변경한다. 이러한 변경은 AI 모델이 이미지를 잘못 인식하도록 만듭니다. 예를 들어, AI가 개를 고양이로 인식하거나 자동차를 소로 인식하게 할 수 있다.

- **포이즈닝 데이터**: 나이트 쉐이드를 사용하면 아티스트는 자신의 작품을 온라인에 업로드할 때 픽셀을 조작하여 AI 모델이 해당 이미지를 학습할 때 오류를 발생시키도록 할 수 있다. 이러한 조작된 데이터가 AI 모델의 학습 데이터셋에 포함되면, 모델의 성능이 저하되거나 비정상적인 출력을 생성하게 된다.
- **방어 메커니즘**: 이 도구는 특히 대규모 데이터셋을 사용하는 AI 모델에 큰 영향을 미칠 수 있다. AI 모델이 잘못된 데이터를 학습하면, 관련된 모든 연관 개념까지 영향을 받아 광범위한 오류가 발생한다. 이는 AI가 특정 주제에 대한 이미지 생성을 시도할 때 비정상적인 결과를 생성하게 만든다.

윤리적 및 법적 영향

나이트 쉐이드는 아티스트들이 자신의 작품이 무단으로 사용되는 것을 방지하고, AI 회사들이 저작권을 존중하도록 유도하는 데 중요한 역할을 할 수 있다. 이는 아티스트들이 더 안전하게 자신의 작품을 공유할 수 있도록 돕고, AI 모델의 데이터 수집 관행에 대한 경각심을 불러일으킬 수 있다.

추가 자료 및 참고문헌

다음 사이트를 통해 더 자세히 알아볼 수 있다:

- MIT Technology Review: How Nightshade helps artists
- World Economic Forum: Explanation of Nightshade
- My Modern Met: Impact of Nightshade on AI art generators

이 도구는 AI와 저작권 보호의 교차점에서 중요한 발전을 이끌어 내며, 앞으로의 AI 발전에 있어서 중요한 윤리적 기준을 제시할 것이다.

Generative AI로 제작된 작품의 소유권

생성형 인공지능으로 제작된 음악의 소유는 누가 가져야 할까? 생성형 인공지능으

로 제작된 음악의 소유권 문제는 현재 법적으로 명확하지 않으며, 각국의 법률과 정책에 따라 다르게 해석될 수 있다. 여기서는 몇 가지 주요 국가의 사례를 소개하고자 한다.

- **미국**: 미국에서는 생성형 AI가 만든 콘텐츠의 저작권 소유권 문제에 대해 명확한 법적 규정이 없다. 그러나 미국 저작권청(US Copyright Office)은 저작권이 부여되려면 인간의 창작이 포함되어야 한다는 입장을 취하고 있다. 이는 AI가 독립적으로 생성한 콘텐츠는 저작권 보호를 받을 수 없음을 의미한다. 따라서 생성 AI가 만든 음악의 경우, 그 소유권은 AI를 만든 개발자나 AI 시스템을 소유한 회사에 귀속될 가능성이 크다.
- **유럽 연합(EU)**: 유럽 연합은 AI와 관련된 지식 재산권 문제에 대해 다양한 연구와 논의를 진행하고 있다. 유럽 연합 지식재산권청(EUIPO)은 AI가 생성한 콘텐츠의 저작권 보호에 대해 명확한 규정을 마련하지 않았지만, 인간의 창작 요소가 포함되어야 저작권이 인정된다는 원칙을 유지하고 있다. 이는 AI가 생성한 음악의 소유권이 인간 창작자가 아닌 AI 시스템을 소유하거나 운영하는 주체에게 귀속될 수 있음을 의미한다.
- **영국**: 영국 저작권청(UK Copyright Service)은 AI가 생성한 작품에 대한 저작권 보호 문제를 다루고 있다. 영국 법은 AI가 생성한 작품의 저작권이 AI 시스템을 운영한 주체에게 귀속된다는 입장을 취하고 있다. 이는 AI가 독립적으로 생성한 음악의 경우, 그 소유권은 AI 시스템을 소유하거나 운영하는 사람이나 기관에게 돌아갈 가능성이 높음을 시사한다.
- **일본**: 일본에서는 AI가 생성한 콘텐츠에 대한 저작권 보호에 대해 명확한 법적 규정이 없지만, 일본 저작권청(Japan Copyright Office)은 AI가 생성한 콘텐츠의 저작권 문제를 해결하기 위한 법적 프레임워크를 마련하고 있다. 일본에서는 AI가 생성한 음악의 소유권이 AI를 개발한 개발자나 AI 시스템을 소유한 회사에 귀속될 가능성이 있다.
- **한국**: 한국에서도 AI가 생성한 콘텐츠에 대한 저작권 문제에 대해 논의가 진행 중인다. 현재 한국의 저작권법은 인간의 창작이 포함된 콘텐츠에 대해서만 저작권을 인정하고 있으며, AI가 독립적으로 생성한 콘텐츠는 저작권 보호를 받을 수

없다. 따라서 AI가 생성한 음악의 소유권은 AI 시스템을 소유하거나 운영하는 주체에게 귀속될 가능성이 크다.

추가 자료 및 참고문헌

- MIT Technology Review: 저작권 문제
- World Economic Forum: 저작권 관련 기사
- My Modern Met: 저작권 보호

이와 같은 상황은 각국의 법적 프레임워크와 정책이 발전함에 따라 변화할 수 있으며, AI가 생성한 콘텐츠의 저작권 문제는 앞으로 더 많은 논의와 연구가 필요할 것이다.

생성형 인공지능이 제작한 작품에 대한 소유권을 표시하기 위해 몇 가지 방법이 있다. 이러한 방법들은 AI가 생성한 콘텐츠의 출처를 명확히 하고, 저작권과 관련된 문제를 해결하는 데 도움이 된다.

- **메타데이터 삽입**: 작품 파일에 메타데이터를 삽입하여 소유권 정보를 포함할 수 있다. 메타데이터는 파일에 포함된 추가 정보로, AI 모델, 생성 날짜, 소유자 정보 등을 기록할 수 있다. 이를 통해 작품의 출처와 소유권을 명확히 할 수 있다.
  - **EXIF 데이터**: 이미지 파일에 주로 사용되며, 카메라 정보, 촬영 날짜, 소유자 정보를 포함할 수 있다.
  - **ID3 태그**: 오디오 파일에 사용되며, 트랙 정보, 아티스트, 앨범, 저작권 정보를 포함할 수 있다.
- **디지털 워터마크**: 디지털 워터마크를 사용하여 작품에 소유권 정보를 삽입할 수 있다. 이는 이미지, 비디오, 오디오 파일 등에 적용될 수 있으며, 맨눈으로는 보이지 않지만 디지털 분석을 통해 확인할 수 있다.
  - **투명 워터마크**: 시각적으로는 보이지 않지만 파일에 삽입되어 소유권 정보를 제공한다.
  - **비가시적 워터마크**: 파일의 비트 스트림에 삽입되어, 데이터 손실 없이 소유권 정보를 제공한다.
- **블록체인 기술**: 블록체인 기술을 사용하여 작품의 소유권을 기록하고 추적할 수 있다. 블록체인은 변조가 불가능한 분산 원장으로, AI가 생성한 작품의 소유권과

거래 기록을 안전하게 저장할 수 있다.

- NFT(Non-Fungible Token): 디지털 작품의 소유권을 증명하기 위해 사용되며, 블록체인상에서 거래와 소유권 변경을 기록할 수 있다.
- **블록체인 기반 인증**: 작품 생성 시점과 소유권을 블록체인에 기록하여 변조를 방지한다.

- **라이선스 문서**: 작품에 대한 소유권을 명확히 하기 위해 라이선스 문서를 작성할 수 있다. 이 문서에는 AI 생성 작품의 소유권자, 사용 조건, 저작권 관련 사항이 포함될 수 있다.
  - CC(Creative Commons) **라이선스**: 다양한 조건하에서 작품의 사용을 허락하는 라이선스 유형을 제공한다.
  - **맞춤형 라이선스 계약**: 특정 사용 조건과 소유권 사항을 명시한 계약서를 작성한다.
- **저작권 등록**: 가능한 경우, AI가 생성한 작품을 공식 저작권 기관에 등록하여 소유권을 법적으로 보호할 수 있다. 이는 분쟁 발생 시 법적 근거를 제공하는 데 유용하다.
  - **국가 저작권청 등록**: 작품을 국가 저작권청에 등록하여 법적 보호를 받는다.
  - **저작권 인증 서비스**: 제3자 인증 서비스를 통해 작품의 소유권과 생성 시점을 공식적으로 증명한다.

추가 자료 및 참고문헌

- EXIF 데이터 설명
- ID3 태그 설명
- 디지털 워터마크 기술
- 블록체인 및 NFT 기술
- Creative Commons 라이선스
- 미국 저작권청

이러한 방법들을 사용하여 생성형 인공지능이 제작한 작품의 소유권을 명확히 하고, 저작권과 관련된 법적 문제를 예방할 수 있다.

④ 딥페이크

딥페이크는 주로 생성적 적대 신경망(Generative Adversarial Networks, GANs)을 사용하여 개발된다.

주요 기술 및 연구 사례

- DeepFaceLab: 얼굴 합성 및 교체를 위한 인기 있는 오픈소스 소프트웨어이다.
- FaceSwap: 다양한 얼굴 합성 작업을 지원하는 또 다른 오픈소스 프로젝트이다.
- StyleGAN: NVIDIA에서 개발한 GAN 모델로, 매우 높은 품질의 이미지를 생성할 수 있다.

딥페이크의 윤리적 이슈

딥페이크(deepfake)는 인공지능(AI) 기술을 사용하여 이미지, 비디오, 오디오 등의 콘텐츠를 조작하는 기술로, 다음과 같은 윤리적 이슈가 존재한다:

- **사생활 침해**: 딥페이크는 개인의 얼굴이나 음성을 무단으로 사용하여 개인의 사생활을 침해할 수 있다. 이는 개인의 명예를 훼손하고 심각한 정신적 피해를 줄 수 있다.
- **허위 정보와 가짜 뉴스**: 딥페이크 기술은 허위 정보를 퍼뜨리는 데 사용될 수 있다. 가짜 뉴스나 조작된 영상이 실제로 일어난 일처럼 퍼지면서 사회적 혼란을 야기할 수 있다.
- **정치적 악용**: 정치인이나 공공 인물의 발언이나 행동을 조작하여 정치적 목적을 달성하려는 시도가 증가하고 있다. 이는 민주주의를 위협하고 공공 신뢰를 저하시킬 수 있다.
- **범죄적 사용**: 딥페이크는 사기, 명예훼손, 사이버 괴롭힘 등의 범죄에 악용될 수 있다. 특히 음란물을 제작하여 피해자를 협박하거나 굴욕감을 주는 경우가 많다.

문제 해결을 위한 방법 및 기술적 노력

- **법적 규제**: 여러 국가에서 딥페이크 관련 법률을 제정하고 있다. 예를 들어, 미국에서는 딥페이크를 사용한 허위 정보 유포를 처벌하는 법안이 마련되고 있다. 법적 규제를 통해 딥페이크의 악용을 방지하려는 노력이 진행되고 있다.
- **인공지능 검출 기술 개발**: 딥페이크 콘텐츠를 식별하기 위한 AI 기반 검출 기술이 개발되고 있다. 딥페이크 검출 기술은 이미지나 영상의 비정상적인 패턴을 분석하여 조작 여부를 판단한다. 예를 들어, 페이스북과 마이크로소프트는 딥페이크 검출 챌린지를 통해 새로운 검출 기술을 개발하고 있다.
- **교육과 인식 제고**: 딥페이크의 위험성을 알리고, 사용자가 가짜 콘텐츠를 식별할 수 있도록 교육하는 것이 중요한다. 공공 기관과 민간 단체는 딥페이크 인식 캠페인을 통해 사용자들에게 경각심을 심어주고 있다.
- **기술적 방어 장치**: 텐츠 생성 시 원본임을 증명할 수 있는 워터마킹(watermarking) 기술을 도입하거나, 블록체인 기술을 활용하여 콘텐츠의 진위 여부를 검증하는 방안이 제안되고 있다. 이러한 기술적 방어 장치는 딥페이크의 무단 사용을 어렵게 만든다.
- **협력적 대응**: 정부, 기술 기업, 학계, 시민 단체가 협력하여 딥페이크 문제를 해결하기 위한 종합적인 접근이 필요하다. 다양한 이해관계자가 협력하여 정책을 수립하고, 기술을 개발하며, 교육 프로그램을 운영하는 것이 중요하다.

추가 자료 및 참고문헌

다음 사이트를 통해 더 자세히 알아볼 수 있다:

- MIT Technology Review: This new data poisoning tool lets artists fight back against generative AI
- World Economic Forum: How Nightshade poisons the data that AI tools use
- My Modern Met: Nightshade "Poisons" AI Art Generators to Help Defend Artists

이러한 노력들은 딥페이크 기술의 악용을 방지하고, 기술의 윤리적 사용을 촉진하는 데 중요한 역할을 할 것이다.

그 외 딥러닝 기술

딥페이크 기술 외에도 다양한 분야에서 딥러닝을 활용한 기술들이 발전하고 있다. 대표적인 기술로 딥보이스(DeepVoice), 딥무비(DeepMovie), 딥페이크 뮤직(DeepFake Music) 등이 있다.

- **딥보이스(DeepVoice)**: 딥보이스는 텍스트를 자연스러운 음성으로 변환하는 음성 합성 기술이다. 이 기술은 주로 텍스트-투-스피치(TTS) 시스템에 사용되며, 주요 특징은 다음과 같다.
  - **자연스러운 음성 합성**: 딥러닝을 사용하여 입력된 텍스트를 자연스러운 인간 음성으로 변환한다.
  - **다양한 음성 스타일**: 여러 목소리와 억양을 학습하여 다양한 스타일의 음성을 생성할 수 있다.
  - **실시간 처리**: 높은 처리 속도로 실시간 음성 합성이 가능하다.

적용 사례

- 가상 비서 및 챗봇: 고객 서비스 및 상호작용을 위한 자연스러운 음성 지원
- 오디오북 및 내비게이션 시스템: 고품질의 음성 안내 제공
- 연구 및 상업적 솔루션
- Baidu의 Deep Voice
- Google의 Tacotron

- **딥무비(DeepMovie)**: 딥무비는 딥러닝 기술을 사용하여 영화 제작 및 편집을 자동화하는 기술이다. 주요 기능은 다음과 같다.
  - **자동 편집**: 영상을 분석하여 자동으로 편집하고, 하이라이트를 추출하거나 장면을 구성한다.
  - **특수 효과**: AI를 사용하여 고품질의 특수 효과를 추가할 수 있다.
  - **스토리텔링**: AI가 스토리 구조를 분석하고 최적의 내러티브 흐름을 생성한다.

적용 사례

- 영화 및 광고 제작: 자동화된 편집 도구를 사용하여 제작 시간과 비용 절감
- 소셜 미디어 콘텐츠: 사용자 생성 콘텐츠의 품질 향상
- 연구 및 상업적 솔루션
- Adobe의 Project Blink
- IBM의 Watson Video Enrichment

- **딥페이크 뮤직(DeepFake Music)**: 딥페이크 뮤직은 딥러닝 기술을 사용하여 음악을 합성하거나 기존 음악을 변형하는 기술이다. 주요 기능은 다음과 같다.
  - **음악 생성**: AI를 통해 새로운 음악을 생성하거나 기존 음악 스타일을 모방한다.
  - **음악 변형**: 특정 아티스트의 스타일로 기존 음악을 변형한다.
  - **리믹스 및 매시업**: 여러 곡을 결합하여 새로운 음악을 자동으로 생성한다.

적용 사례

- 음악 제작: 작곡가와 프로듀서를 위한 도구로 활용
- 엔터테인먼트: 맞춤형 음악 제작 및 리믹스
- 연구 및 상업적 솔루션:
- OpenAI의 Jukedeck
- Sony의 Flow Machines

추가 자료 및 참고문헌

다음 자료들을 통해 더 자세히 알아볼 수 있다:

- Baidu Deep Voice
- Google Tacotron
- Adobe Project Blink
- IBM Watson Video Enrichment
- OpenAI Jukedeck
- Sony Flow Machines

이와 같은 기술들은 엔터테인먼트, 미디어, 고객 서비스 등 다양한 분야에서 혁신을 가져오고 있다. 하지만 이러한 기술들은 윤리적 문제를 동반할 수 있으므로, 기술의 사용에 있어서 책임감 있는 접근이 필요하다.

⑤ 러다이트 운동의 현대적 사례

러다이트 운동은 19세기 초 영국에서 기계화로 인한 일자리 상실에 반발하여 기계를 파괴한 노동자 운동을 의미한다. 현대에는 인공지능과 자동화 기술의 도입으로 유사한 갈등이 발생하고 있다. 생성형 인공지능은 특히 예술, 미디어, 금융 등 다양한 분야에서 인간의 역할을 대체할 가능성이 있어 이에 대한 저항이 나타나고 있다.

분야별 사례

- 예술과 미디어

  AI 아트의 저항: 일부 예술가들은 AI가 생성한 예술 작품이 자신들의 창작활동을 위협한다고 주장하며, AI 아트에 반대하는 캠페인을 벌이고 있다. 예를 들어, AI가 그린 그림이 경매에서 높은 가격에 판매되자 이에 반발하는 움직임이 있었다.

- 작가와 콘텐츠 크리에이터

  AI 작문 도구 반대: 작가와 기자들은 AI가 작성한 기사와 문서가 자신의 직업을 위협한다고 주장하며, AI 작문 도구의 사용을 제한하려는 움직임이 있다. 최근 미국 작가 조합은 AI의 사용을 규제하는 법적 조치를 요구했다.

- 금융 부문

  자동화 저항: 금융 분석가와 트레이더들은 AI와 머신러닝 기술이 그들의 업무를 대체할 것을 우려하며, AI 도입에 반대하는 사례가 있다. 이는 금융 산업 전반에 걸쳐 논의되고 있는 문제이다.

- **기술 일자리 대체에 대한 저항**: AI와 자동화 기술이 발전하면서 많은 노동자들이 일자리를 잃거나 직무가 변화하게 되었다. 예를 들어, 자동화된 고객 서비스, 물류, 제조업 등에서 인간 노동자를 대체하는 경우가 증가하면서 저항 움직임이 일어나고 있다.

  사례) 아마존 창고의 자동화 시스템 도입으로 인해 많은 창고 노동자들이 일자리를 잃게 되었고, 이에 대한 저항과 파업이 발생했다.

- **창작자와 예술가들의 반발**: AI가 음악, 미술, 글쓰기 등 창작활동에 사용되면서

인간 창작자들의 역할이 축소되는 현상이 나타나고 있다. 이는 예술가들 사이에서 저항 운동을 불러일으키고 있다.

사례) AI가 그림을 그리는 데 사용되면서 전통적인 예술가들이 AI의 사용을 반대하며 작품 전시회를 보이콧하거나 항의하는 사례가 있다.

- **정보와 미디어 산업의 변화:** AI가 뉴스 기사를 작성하거나 정보를 수집하고 분석하는 데 사용되면서 기자나 편집자 등의 역할이 변화하고 있다. 이는 미디어 종사자들 사이에서 저항을 일으키고 있다.

  사례) 일부 언론사에서 AI가 작성한 기사를 사용하기 시작하면서 기자 협회와 노동조합이 이를 반대하는 성명을 발표했다.

문제와 갈등 해소 방법

- **재교육 및 직업 전환 프로그램:** 정부와 기업은 AI로 인해 일자리를 잃은 노동자들을 위해 재교육 프로그램을 제공하고, 새로운 직업으로의 전환을 지원해야 한다. 이는 노동자들이 새로운 기술을 습득하고, AI 시대에 맞는 새로운 역할을 찾을 수 있도록 도와준다.
- **AI와 인간의 협업 모델:** AI가 인간의 능력을 보완하는 협업 모델을 구축함으로써, 완전한 대체보다는 보조적인 역할을 강조할 수 있다. 예를 들어, AI는 데이터 분석을 수행하고, 인간은 이를 바탕으로 창의적이고 전략적인 결정을 내리는 방식이다.
- **윤리적 AI 개발 및 사용:** AI 개발자와 기업은 AI 기술의 윤리적 사용을 보장하고, 투명성과 책임성을 강화해야 한다. AI의 영향을 받는 모든 이해관계자들과의 협력을 통해 공정하고 포괄적인 AI 정책을 수립하는 것이 중요하다.
- **공정한 이익 분배:** AI와 자동화 기술로 인한 경제적 이익이 공정하게 분배될 수 있도록 정책을 마련해야 한다. 이를 통해 기술 발전의 혜택이 모든 사회 구성원에게 돌아가도록 해야 한다.

  예시) 핀란드는 기본소득 실험을 통해 기술 발전으로 인한 경제적 이익이 사회

전체에 공평하게 분배될 수 있는 가능성을 탐구하고 있다.

- **정책 및 규제 마련**: 정부는 AI로 인한 사회적 영향을 최소화하기 위해 적절한 규제와 정책을 마련해야 한다. 이는 AI 기술의 무분별한 도입을 방지하고, 노동자의 권리를 보호하는 데 도움이 된다.

추가 자료 및 참고문헌

- MIT Technology Review
- World Economic Forum
- My Modern Met

6 생성형 인공지능의 무기화 가능성

증거와 사례

- 허위 정보 및 프로파간다

– **딥페이크 비디오**: 딥페이크 기술을 사용해 정치인, 기업인, 유명인의 얼굴과 목소리를 조작하여 허위 정보를 퍼뜨릴 수 있다. 예를 들어, 2020년 미국 대통령 선거 기간 동안 딥페이크 영상이 사용될 가능성에 대해 많은 우려가 제기되었다.

– **텍스트 생성 AI**: OpenAI의 GPT-3와 같은 언어 모델은 대규모의 가짜 뉴스를 생성하여 소셜 미디어에서 허위 정보를 퍼뜨릴 수 있다. 이는 사회적 혼란을 일으키고 정치적 프로파간다에 악용될 수 있다.

- 자동화된 사이버 공격

– **악성 코드 생성**: AI는 복잡한 악성 코드를 자동으로 생성하고 배포할 수 있다. 연구자들은 AI를 사용해 기존의 악성 코드를 변형하여 새로운 변종을 만드는 실험을 통해 이러한 가능성을 입증했다.

– **피싱 이메일**: AI가 생성한 피싱 이메일은 인간이 작성한 것보다 더 정교하고 설

득력 있게 만들 수 있다. 이는 피싱 공격의 성공률을 높이고, 금융 사기나 개인 정보 유출 등의 문제를 야기할 수 있다.

- 무기 시스템의 자동화

– **자율 무기 시스템**: 드론과 같은 자율 무기 시스템에 AI를 적용하여 목표를 자동으로 탐지하고 공격할 수 있다. 이는 인간의 통제를 벗어나 예기치 않은 민간인 피해를 초래할 수 있는 위험이 있다. 예를 들어, 터키에서 개발된 자율 드론이 리비아 내전에서 사용되었다는 보고가 있다.

– **군사 전략 시뮬레이션**: AI는 군사 전략 시뮬레이션에서 적의 행동을 예측하고 최적의 대응 전략을 자동으로 생성할 수 있다. 이는 군사적 긴장감을 높이고, 오판으로 인한 무력 충돌을 촉발할 위험이 있다.

방지 방안

- 규제와 정책 마련

– **국제 협약**: 국가 간 협력을 통해 AI의 무기화 방지를 위한 국제 협약을 체결해야 한다. 이는 자율 무기 시스템의 사용을 규제하고, AI 기술의 군사적 활용을 제한하는 내용을 포함할 수 있다.

– **법적 규제**: 각국 정부는 AI 기술의 개발과 사용에 대한 법적 규제를 마련해야 한다. 예를 들어, 유럽 연합은 AI 윤리 가이드라인을 통해 AI 사용의 윤리적 기준을 제시하고 있다.

- 기술적 방어 메커니즘

– **AI 검출 및 방어 시스템 개발**: 딥페이크와 같은 AI 기반 허위 정보를 탐지하고 차단하는 기술을 개발해야 한다. 이는 영상 및 오디오 검증 시스템을 통해 딥페이크 콘텐츠를 식별하고, 소셜 미디어 플랫폼에서 허위 정보를 신속히 제거하는 데 사용될 수 있다.

– **사이버 보안 강화**: AI가 생성한 악성 코드와 사이버 공격을 방어하기 위한 보안 시스템을 강화해야 한다. 이는 AI 기반 사이버 보안 솔루션을 통해 이상 징후를 실시간으로 모니터링하고, 잠재적인 위협을 신속히 차단하는 방법을 포함할 수

있다.

- 교육과 인식 제고

– **대중 교육**: 대중에게 AI 기술의 위험성과 안전한 사용법을 교육해야 한다. 이는 AI 기술의 악용 가능성을 줄이고d, 사회 전반에 걸쳐 AI에 대한 인식을 높이는 데 도움이 된다.

– **전문가 교육**: AI 개발자와 연구자들에게 윤리적 AI 개발과 사용에 대한 교육을 제공하여, AI 기술이 윤리적으로 활용될 수 있도록 한다.

추가 자료 및 참고문헌

- MIT Technology Review: 딥페이크 및 AI 윤리
- World Economic Forum: AI 무기화 관련 기사
- My Modern Met: AI 윤리 가이드라인

이와 같은 방지 방안을 통해 생성형 인공지능의 무기화를 예방하고, AI 기술이 인간 사회에 긍정적으로 기여할 수 있도록 해야 한다.

생성형 AI 플레이북

텍스트에서 **멀티미디어**까지

저 자	한선관 · 류미영 · 이문주 · 신상규 김지혜 · 강남선 · 임새이
발 행 인	김지영
발 행 처	자유아카데미
주 소	경기도 파주시 회동길 37-42 파주출판도시
전 화	031-955-1321
팩 스	031-955-1322
홈페이지	www.freeaca.com
전자우편	main@freeaca.com (대표) editor@freeaca.com (편집) crm@freeaca.com (영업)
등 록	제406-2003-017호, 1980. 7. 12
제1판1쇄	2025년 1월 20일 발행

저자와의
협의하에
인지생략

무단 복제를 금하며, 잘못된 책은 바꾸어 드립니다.

ISBN 979-11-5808-665-7 93000